

## Guia didático do Tech Challenge Fase 2

Este é o guia da pipeline híbrida para análise da alfabetização no Brasil. O documento explica a teoria das aulas da Pós Tech e mostra o que foi construído no repositório Alfabetiza Cursor. Foi escrito para leitura em voz alta: frases completas, ordem linear e sem cabeçalho, rodapé ou número de página.

Como usar este material. Ouça na ordem. Cada parte começa pela teoria, o porquê, e depois explica onde isso aparece no projeto, o como.

### Parte 1. Para que serve este projeto

O Tech Challenge da Fase 2 pede que você atue como um time de engenharia de dados de uma organização pública. O tema é a alfabetização infantil no Brasil.

A ideia central em uma frase é a seguinte. Existe uma meta de política pública: todas as crianças alfabetizadas até o fim do segundo ano do ensino fundamental, até o ano de dois mil e trinta. Para saber se o país está no caminho, usamos o Indicador Criança Alfabetizada.

O ponto de corte setecentos e quarenta e três significa o seguinte. A Pesquisa Alfabetiza Brasil, do Inep, em dois mil e vinte e três, definiu que, na escala de proficiência do Saeb, a partir de setecentos e quarenta e três pontos a criança pode ser considerada alfabetizada. O indicador é o percentual de estudantes que atingem esse patamar.

Por que precisa de uma pipeline de dados? Porque as informações estão espalhadas: metas nacionais, estaduais e municipais; cadastros de unidade federativa e município; microdados de alunos; e resultados do indicador. Sem integrar essas fontes com qualidade, um gestor não consegue comparar meta com resultado nem priorizar onde agir.

No nosso repositório, há também o arquivo de contexto de negócio na pasta docs. A camada Gold entrega os produtos analíticos que um gestor usaria: indicador por município, comparação com a meta e evolução no tempo.

### Parte 2. O que é uma pipeline de dados

Pipeline é uma sequência automatizada de passos que leva o dado da origem até um formato confiável para análise. Em engenharia de dados, costumamos falar em ETL, ou seja, extrair, transformar e carregar.

Extrair significa buscar dados da origem, por exemplo uma API, um arquivo, um banco ou a plataforma Base dos Dados. Transformar significa limpar, tipar, juntar tabelas e calcular campos. Carregar significa gravar o resultado em um armazenamento analítico.

No lago de dados moderno, muitas vezes fazemos primeiro a carga do bruto e depois as

transformações em camadas. Isso casa com a arquitetura medalhão, que veremos a seguir.

### **Batch versus streaming**

Batch processa um volume histórico de uma vez, em janelas diárias ou semanais. É ideal para metas, municípios e séries anuais. Em geral é mais barato e mais simples.

Streaming processa eventos contínuos, quase em tempo real. É ideal para situações como: acabou de chegar uma atualização do indicador do município X. Para isso usamos filas ou mensageria, por exemplo Kafka.

Pipeline híbrida significa usar os dois juntos. O enunciado exige isso: históricos em batch e simulação de eventos em streaming.

No nosso repositório, o batch está nos scripts load bronze, load silver e load gold, dentro da pasta pipelines batch. O streaming está no producer de eventos, dentro da pasta pipelines streaming. Esse producer grava eventos na Bronze e, opcionalmente, pode publicar no Kafka.

## **Parte 3. Arquitetura medalhão: Bronze, Silver e Gold**

Esta é a ideia central da disciplina Arquitetura de Big Data. A metáfora da medalha, do bronze para a prata e depois para o ouro, organiza o lago de dados em três níveis de refinamento.

### **Camada Bronze, o dado bruto**

A Bronze guarda o que chegou, com pouca ou nenhuma transformação. Ela preserva histórico e rastreabilidade: quando o dado entrou e de onde veio. Se algo der errado na Silver, você ainda tem o original para reprocessar.

No nosso projeto, cada entidade vira arquivo Parquet na pasta data bronze, organizada por entidade e por data. Há colunas técnicas de data de ingestão, fonte e modo, indicando se veio de batch ou de streaming.

### **Camada Silver, o dado tratado e integrado**

A Silver faz limpeza: trata nulos, tipagem, padronização de nomes e textos. Também faz deduplicação e validação de chaves, como identificador de município, identificador de unidade federativa e ano. Por fim, integra: junta o indicador com a meta e com a dimensão município.

No nosso projeto, o script load silver gera, entre outras, a tabela indicador meta integrado, já com o campo de diferença em relação à meta e o campo que indica se a meta foi atingida.

### **Camada Gold, o dado analítico**

A Gold contém tabelas agregadas e fatos prontos para dashboard, consulta SQL e, no futuro, aprendizado de máquina. Não é lugar de JSON bagunçado: é um contrato estável para o negócio.

No nosso projeto, a Gold entrega o mínimo pedido pelo enunciado: indicador de alfabetização por município; comparativo entre meta e resultado por unidade federativa e pelo Brasil; e evolução temporal por município, unidade federativa e Brasil.

Uma analogia simples ajuda. Bronze é a caixa de entrada do correio. Silver são as cartas abertas, organizadas e grampeadas por assunto. Gold é o relatório executivo que a diretoria lê.

### **Correspondência com a aula de nuvem**

Na aula de ETL em AWS Glue, os buckets se chamam SOR, SOT e SPEC. É o mesmo medalhão com outros nomes. SOR corresponde à Bronze. SOT corresponde à Silver. SPEC corresponde à Gold. Os templates estão no arquivo glue jobs template, na pasta pipelines batch.

## **Parte 4. Data Lake, Warehouse e Lakehouse**

Data Lake armazena arquivos em larga escala, por exemplo no S3 da Amazon, em formatos como Parquet. É flexível e barato, mas sem governança vira pântano de dados.

Data Warehouse é um banco analítico estruturado, como BigQuery ou Redshift. É ótimo para SQL e painéis de negócio, com esquemas mais rígidos e, em geral, custo maior.

Lakehouse une o melhor dos dois: arquivos no lake com uma camada de tabela, como Delta, permitindo qualidade e consultas. Databricks, usado na aula, é um exemplo de plataforma lakehouse.

No nosso repositório, o desenvolvimento local usa a pasta data como um mini lake em Parquet. A nuvem alvo do enunciado é AWS com S3 e Glue. A demo didática espelha os notebooks Databricks um a quatro da turma.

## **Parte 5. Bancos relacionais e MySQL**

A disciplina de bancos relacionais ensina tabelas, chaves primárias, chaves estrangeiras e SQL. Isso não desaparece no Big Data. Dimensões estáveis, como unidade federativa, município e metas, frequentemente nascem ou são governadas em um banco relacional e depois entram no lake.

Chave primária identifica unicamente uma linha, por exemplo o identificador do município. Chave estrangeira garante que o município da meta existe na dimensão município. Normalização separa quem é o município de qual foi o resultado no ano X.

No nosso repositório, o arquivo SQL de dimensões MySQL cria as tabelas de unidade federativa, município e fatos de meta e indicador, além de uma view que antecipa a ideia da Gold.

## **Parte 6. NoSQL e eventos em JSON**

Bancos NoSQL, por exemplo DynamoDB, e streams de eventos muitas vezes entregam JSON com tipos explícitos, como S para texto e N para número. Na aula de Big Data isso é simulado antes da Bronze.

No streaming do projeto, o producer gera eventos no mesmo espírito: uma imagem nova com atualização do percentual de alfabetizados de um município. A Bronze guarda o evento. A Silver achata o JSON e mescla com o indicador batch. A última escrita vence.

No nosso repositório, isso está no producer de eventos. Para rodar junto com a pipeline, use o módulo `pipelines.run_pipeline` com a opção `with-streaming`.

## **Parte 7. Kafka, mensageria para streaming**

Kafka é um sistema de log distribuído de mensagens. Produtores publicam eventos em tópicos. Consumidores leem esses eventos. Isso desacopla quem gera o dado de quem processa.

Tópico é o canal nomeado, por exemplo `alfabetiza.indicador.updates`. Producer é quem publica, no nosso caso a simulação de atualização de indicador. Consumer é quem lê e grava na Bronze.

Para estudar sem pagar nuvem, o projeto também tem um file sink: grava os mesmos eventos na pasta `data/bronze/events/indicador`. O conceito pedagógico é o mesmo.

## **Parte 8. Qualidade de dados**

Dado errado em dashboard vira decisão errada. O enunciado pede validações mínimas: verificar duplicidade, ou seja, a mesma chave duas vezes; detectar valores ausentes em campos críticos; validar chaves de relacionamento; e checar consistência entre tabelas, por exemplo se o ano do indicador existe na meta.

No nosso repositório, rode o módulo `quality.validate`. O resultado fica no arquivo `quality report`, dentro da pasta `logs`. A orquestração falha se a qualidade não passar.

## **Parte 9. FinOps, custo em nuvem**

FinOps é a disciplina de gastar bem na nuvem. Não significa deixar de usar nuvem. Significa usar o recurso certo, no tamanho certo, só quando precisa.

Práticas importantes: usar Parquet com particionamento para ler menos bytes e pagar menos; usar computação sob demanda, como Glue ou Databricks serverless, pagando enquanto roda; desenvolver com amostras locais para ter custo zero de nuvem no dia a dia; e aplicar qualidade cedo, para evitar reprocessar a Gold e os painéis à toa.

No nosso repositório, o arquivo de FinOps e monitoramento na pasta `docs` traz uma estimativa aproximada de cinco a vinte dólares por mês para uma demo acadêmica em AWS, além dos sinais

de monitoramento: latência, volume e falhas.

## **Parte 10. Mapa das aulas da Pós Tech para as pastas do projeto**

O repositório da turma é o POSTECH AI Scientist, pasta Fase 2, da Ana Raquel Café.

A pasta Arquitetura de Big Data, com notebooks um a quatro do medalhão, corresponde aos notebooks e aos scripts load da pasta pipelines batch do nosso projeto.

A pasta ETL Pipelines, com Pandas, PySpark, Kafka e Glue, corresponde às pastas pipelines batch e pipelines streaming, e ao template de jobs Glue.

A pasta de bancos relacionais corresponde ao script SQL de dimensões MySQL.

A pasta de NoSQL corresponde ao formato JSON do producer de eventos.

Há mais detalhes no arquivo mapa aulas, dentro da pasta references.

## **Parte 11. O que cada parte do repositório faz**

O arquivo config, em pipelines, guarda caminhos, o ponto de corte setecentos e quarenta e três, e os nomes de recursos AWS e Kafka.

O script generate sample data cria arquivos CSV didáticos para rodar offline. O load bronze faz a ingestão bruta com metadados. O load silver faz limpeza, deduplicação e integração. O load gold materializa os produtos analíticos.

Os scripts de streaming contêm o producer e o consumer de eventos. O run pipeline orquestra tudo. O monitor health faz a checagem de saúde depois da execução. O validate, na pasta quality, aplica as regras de qualidade do enunciado.

A pasta data sample tem as entradas versionadas. As pastas bronze, silver e gold dentro de data recebem as saídas locais. A pasta reports gold preview tem CSV da Gold para abrir no Excel ou Power BI. A pasta docs tem os textos de entrega: negócio, arquitetura, FinOps, vídeo e Git.

## **Parte 12. Como rodar o projeto**

No diretório do projeto Alfabetiza Cursor, crie um ambiente virtual Python. No Windows, ative o ambiente e instale as dependências a partir do arquivo requirements.

Em seguida rode o módulo pipelines.run\_pipeline com a opção with-streaming. Depois rode o módulo pipelines.monitor\_health.

Se a saída mostrar health OK, e se o quality report mostrar passed igual a true, a pipeline de ponta a ponta funcionou. Abra os CSV em reports gold preview para ver os resultados.

## **O que acontece ao rodar, em ordem**

Primeiro, o sistema gera ou usa as amostras e copia para data raw. Segundo, a Bronze batch grava Parquet particionado. Terceiro, o producer cria cerca de dez eventos de atualização do indicador. Quarto, a Silver trata, mescla eventos e integra com metas. Quinto, a qualidade valida chaves, nulos e duplicatas. Sexto, a Gold materializa as tabelas analíticas e os CSV de preview.

## **Parte 13. Aplicação em inteligência artificial**

Você não precisa entregar um modelo treinado nesta fase. Precisa explicar como a Gold habilita inteligência artificial depois.

Predição: estimar o percentual de alfabetizados futuro por município, usando histórico, meta, unidade federativa e volume avaliado. Desigualdade: encontrar grupos de municípios cronicamente abaixo da meta. Política pública: priorizar intervenção onde a diferença entre meta e resultado é maior.

Uma frase pronta para o vídeo é esta. A engenharia de dados entrega um ativo confiável na Gold. A ciência de dados consome esse ativo para prever e priorizar.

## **Parte 14. Git com branches e pull requests**

O enunciado exige histórico Git mostrando evolução, branches e pull requests. No Alfabetiza Cursor já existem branches com prefixo feat e merges na main no estilo de pull request. Veja o arquivo de fluxo Git na pasta docs para publicar no GitHub.

## **Parte 15. Roteiro rápido do vídeo de cinco minutos**

Nos primeiros quarenta e cinco segundos, apresente o problema: alfabetização, ponto de corte setecentos e quarenta e três, meta dois mil e trinta, e dados fragmentados.

Nos noventa segundos seguintes, explique a arquitetura: batch mais streaming, mais Bronze, Silver e Gold. Mostre o diagrama.

Nos sessenta segundos seguintes, mostre o valor: comparação entre meta e resultado e priorização territorial. Mostre um CSV da Gold.

Nos quarenta e cinco segundos seguintes, fale do potencial de inteligência artificial: predição, desigualdade e política baseada em evidência.

Nos trinta segundos finais, faça o fechamento. O texto completo está no roteiro de vídeo, na pasta docs.

## **Parte 16. Glossário mínimo**

Pipeline é o fluxo automatizado de dados. Ingestão é a entrada dos dados no sistema. Schema é a estrutura de colunas de uma tabela. Partição é uma fatia de dados, por exemplo por data, para ler menos. Parquet é um formato colunar compacto, padrão em lakes. Deduplicação é remover linhas repetidas pela chave. Join, ou merge, é juntar tabelas por chave comum. Observabilidade é saber se a pipeline falhou, atrasou ou processou pouco. FinOps é gestão de custo em nuvem. Base dos Dados é uma plataforma de dados públicos brasileiros, origem sugerida pelo enunciado.

## **Parte 17. Checklist de estudo se as aulas ficaram pela metade**

Estude nesta ordem, cerca de uma a duas horas por bloco. Bloco A, negócio: esta Parte 1 e o arquivo de contexto de negócio. Bloco B, medalhão: esta Parte 3; rode a pipeline e inspecione as pastas bronze, silver e gold. Bloco C, híbrida: Partes 2 e 7; olhe o producer de eventos. Bloco D, qualidade e FinOps: Partes 8 e 9; veja o quality report e o documento de FinOps. Bloco E, contar a história: roteiro de vídeo e o README.

Mensagem final. Você não precisa ter assistido cem por cento das aulas para defender o projeto. Precisa entender o porquê do medalhão, a diferença entre batch e streaming, o valor da Gold para política pública, e saber rodar e explicar o que está no Alfabetiza Cursor. Este guia foi feito para isso.