

Guia extensivo: aulas da Pós Tech e o Tech Challenge Fase 2

Este documento é um segundo guia, mais longo que o guia didático resumido. Ele ensina, passo a passo, o que você precisa entender nas quatro pastas de material da turma para concluir o projeto Alfabetiza Cursor, do Tech Challenge Fase 2.

Foi escrito para leitura em voz alta: sem cabeçalho, sem rodapé, sem número de página, com frases completas e seções bem nomeadas.

Os quatro materiais oficiais da turma são os seguintes. Primeiro, Arquitetura de Big Data. Segundo, Banco de dados relacionais para cientistas de dados. Terceiro, NoSQL para ciência de dados. Quarto, ETL Pipelines. Todos ficam no repositório POSTECH AI Scientist, pasta Fase 2, da Ana Raquel Café.

O desafio da FIAP pede uma pipeline híbrida, batch mais streaming, em arquitetura medalhão, sobre o Indicador Criança Alfabetizada, com qualidade, FinOps, README completo, histórico Git com pull requests e vídeo executivo de até cinco minutos.

Como estudar este guia

Siga a ordem dos módulos. Em cada módulo você verá três blocos: o que a aula ensina; a teoria por trás; e como aplicar no Alfabetiza Cursor. No final há um roteiro de execução do projeto e um checklist de entrega.

Se você perdeu aulas, não tente assistir tudo de uma vez. Este texto já organiza o mínimo necessário para defender o trabalho com segurança.

Módulo zero. Visão geral do que o Tech Challenge exige

O problema de negócio em linguagem simples

O Brasil tem o Compromisso Nacional Criança Alfabetizada. A meta é alfabetizar todas as crianças até o fim do segundo ano, até dois mil e trinta. A Pesquisa Alfabetiza Brasil definiu o ponto de corte setecentos e quarenta e três na escala Saeb. O Indicador Criança Alfabetizada é o percentual de estudantes nesse patamar.

Para apoiar políticas públicas, é preciso integrar metas nacionais, estaduais e municipais, dados de território, microdados de alunos e indicadores de desempenho. Essa integração é o trabalho de engenharia de dados do desafio.

Entregáveis que não podem faltar

Código da pipeline com camadas Bronze, Silver e Gold. Ingestão batch e streaming. Scripts de qualidade. Implementação ou demonstração em nuvem, preferencialmente AWS alinhada à aula. README com contexto, arquitetura, tecnologias, trade-offs, monitoramento, FinOps e uso em IA. Histórico Git com branches e pull requests. Vídeo executivo de até cinco minutos.

Onde cada aula entra no desafio

Arquitetura de Big Data ensina o medalhão e o fluxo um, dois, três, quatro. Bancos relacionais ensinam dimensões, chaves e SQL, úteis para UF, município e metas. NoSQL ensina o formato de eventos que alimenta o braço streaming. ETL Pipelines ensina ETL com Pandas e PySpark, Kafka e jobs Glue na AWS com buckets SOR, SOT e SPEC.

Módulo 1. Banco de dados relacionais

Material da turma: pasta Banco de dados relacionais para cientistas de dados. Há guia de instalação MySQL e DBeaver, e uma pasta app com script SQL e gerador de dados.

O que esta disciplina quer que você saiba

Um banco relacional organiza dados em tabelas com linhas e colunas. Cada tabela representa uma entidade do mundo real, por exemplo município ou meta anual. Relações entre tabelas são feitas por chaves.

Chave primária identifica unicamente uma linha. Exemplo: o código IBGE do município. Chave estrangeira garante que um valor em uma tabela exista em outra. Exemplo: a meta municipal só pode referenciar um município que exista na dimensão município.

Normalização evita repetir a mesma informação em vários lugares. Em vez de repetir o nome do município em todas as linhas de resultado, guardamos o nome na dimensão município e usamos só o identificador nos fatos.

Por que isso importa no Tech Challenge

O enunciado pede entidades como UF, município, meta Brasil, meta por UF, meta por município e dados de alunos. Isso é naturalmente modelável como dimensões e fatos. Mesmo que a pipeline rode em lake e Parquet, o raciocínio relacional continua válido na Silver e na Gold.

Como estudar o material da turma

Instale MySQL e DBeaver com o guia da pasta. Abra o arquivo globaltech database ponto sql para ver como a aula cria tabelas e relacionamentos. Observe tipos de dados, chaves e nomes de colunas. Não copie o domínio de vendas da aula. Copie o estilo de modelagem.

Como aplicar no Alfabetiza Cursor

No projeto, o arquivo SQL de dimensões MySQL, na pasta sql, cria dim UF, dim município e fatos de meta e indicador, além de uma view que compara meta e resultado. Use isso para explicar no README que as origens relacionais alimentam o lake. Na prática local, as mesmas entidades também existem como CSV em data sample.

Exercício sugerido. No DBeaver, rode o SQL do projeto. Depois importe os CSV de UF e município. Faça um SELECT que junte município com meta. Isso fixa a ideia de join, que a Silver fará em escala.

Módulo 2. NoSQL para ciência de dados

Material da turma: pasta NoSQL para ciência de dados. No GitHub há pouco código; o README aponta para material no Google Drive. O padrão prático de eventos NoSQL também aparece no material de Arquitetura de Big Data, na simulação de DynamoDB Streams.

O que é NoSQL, em termos simples

NoSQL cobre bancos que não seguem o modelo clássico só de tabelas relacionais. Exemplos comuns: documentos, chave valor, colunar e grafos. DynamoDB é um banco de chave valor e documentos, muito usado em aplicações transacionais na AWS.

Em sistemas reais, mudanças nesses bancos viram eventos. DynamoDB Streams, por exemplo, emite registros de inserção, alteração e exclusão. Esses eventos costumam chegar ao lake em JSON, muitas vezes com tipos explícitos: S para string, N para número, e NULL para valor nulo.

Por que o desafio fala de streaming e eventos

A alfabetização, no mundo real, também gera atualizações: nova medição, revisão de meta, correção de indicador. O enunciado pede simular ingestão quase em tempo real. Eventos NoSQL são o modelo mental certo para isso, mesmo que a fonte final seja a Base dos Dados.

Como estudar

Se tiver acesso ao Drive da disciplina, leia a parte de modelagem e de eventos. No material de Big Data, abra o notebook um, criação de origens transacionais, e observe o JSON no estilo DynamoDB. Entenda como from json e explode transformam evento aninhado em tabela.

Como aplicar no Alfabetiza Cursor

O producer de eventos cria mensagens com event name, event source e New Image, atualizando o percentual de alfabetizados de um município. A Bronze guarda o evento bruto. A Silver achata o JSON e mescla com o indicador batch. Assim você demonstra o braço streaming sem precisar de DynamoDB real.

Exercício sugerido. Rode o producer e abra o arquivo JSON L gerado na pasta de eventos. Leia um evento em voz alta e explique cada campo. Depois rode a Silver e veja se o município atualizado mudou na tabela integrada.

Módulo 3. Arquitetura de Big Data e medalhão

Material da turma: pasta Arquitetura de Big Data. Este é o coração conceitual do Tech Challenge. A aula três organiza notebooks um a quatro mais um tutorial hands on de PySpark no Databricks Free Edition.

Data Lake versus Data Warehouse

Data Lake guarda arquivos em grande volume, com schema flexível, bom custo e boa escala. O risco é virar pântano se não houver organização e qualidade. Data Warehouse guarda dados bem modelados para SQL e BI, com mais governança e, em geral, mais custo. Lakehouse tenta unir os dois: arquivos no lake com camada de tabela confiável, como Delta no Databricks.

Arquitetura medalhão, a teoria completa

Bronze é a zona raw. Você preserva o dado como chegou, ou bem próximo disso, com metadados de ingestão. Objetivo: rastreabilidade e reprocessamento.

Silver é a zona tratada. Você limpa, tipa, padroniza, deduplica e integra. Objetivo: dataset confiável e reutilizável por vários consumidores.

Gold é a zona analítica. Você cria tabelas prontas para dashboard, relatório e machine learning. Objetivo: responder perguntas de negócio sem o analista refazer joins complexos toda vez.

O que cada notebook da aula faz

Notebook um cria origens simuladas no schema origens. Simula DynamoDB, CDC ou DMS de clientes, e arquivos de vendas. Aqui ainda não existe medalhão: só a chegada do dado.

Notebook dois lê as origens, interpreta JSON e grava tabelas bronze com dados raw e metadados de ingestão.

Notebook três lê bronze, aplica limpeza, padronização, tipagem e deduplicação, e grava silver.

Notebook quatro lê silver, faz join entre fatos e dimensões, agrega e grava gold.

O tutorial hands on usa essas tabelas para ensinar select, filtro, limpeza, joins, agregações, funções de janela, performance e persistência com PySpark.

Ordem de estudo recomendada nesta pasta

Primeiro, leia o README da pasta para entender a ordem. Segundo, se puder, importe os notebooks no Databricks Free Edition e execute um a quatro. Terceiro, mesmo sem Databricks, leia os arquivos ponto py equivalentes e anote quais transformações acontecem em cada camada. Quarto, traduza mentalmente vendas e clientes para indicador, meta e município.

Como aplicar no Alfabetiza Cursor

O projeto espelha exatamente essa ordem. Geração de amostras e raw equivale às origens. Load bronze equivale ao notebook dois. Load silver equivale ao notebook três, inclusive integração. Load gold equivale ao notebook quatro, com agregações de município, UF e Brasil e evolução temporal.

Diferença importante: o domínio não é varejo. É alfabetização. Na defesa, diga claramente: reaproveitamos o esqueleto da aula e trocamos o caso de negócio.

Exercício sugerido. Depois de rodar a pipeline, abra um Parquet da Bronze e um da Silver do mesmo indicador. Liste três diferenças. Em seguida abra uma tabela Gold e explique qual pergunta de gestão ela responde.

Módulo 4. ETL Pipelines

Material da turma: pasta ETL Pipelines. Ela se divide em três frentes. Primeiro, pipeline ETL com Pandas e PySpark. Segundo, Kafka. Terceiro, cloud com AWS Glue.

Frente A. ETL com Pandas e PySpark

ETL é o ciclo extrair, transformar e carregar. Pandas é excelente para volumes menores, prototipagem e ensino. PySpark entra quando o volume cresce ou quando você está no Databricks e no Glue.

Nos notebooks da pasta um, Pipeline ETL, a aula demonstra o fluxo completo em duas tecnologias. O aprendizado-chave não é a sintaxe: é garantir que extração, transformação e carga estejam separadas, testáveis e observáveis.

No Alfabetiza Cursor, a implementação local usa Pandas e Parquet de propósito, para rodar sem custo e ainda assim respeitar o medalhão. Os templates Glue mostram como a mesma lógica sobe para Spark na AWS.

Frente B. Kafka e streaming

A pasta dois, Kafka, tem quatro demos. Parte um: setup e tópicos. Parte dois: produce e consume. Parte três: streaming com janelas e alertas. Parte quatro: confiabilidade e tempo.

Conceitos que você precisa falar com segurança. Produtor publica eventos. Tópico é o canal. Consumidor processa. Offset marca até onde o consumidor leu. Partições permitem escala. Janelas agregam eventos por intervalo de tempo. Alertas disparam quando uma regra de negócio ou de operação é violada.

No projeto, o streaming pode rodar de dois jeitos. Jeito didático e gratuito: file sink na Bronze de eventos. Jeito alinhado à aula: producer e consumer com Kafka local. Os dois são válidos se você explicar o conceito e mostrar evidência nos logs.

Exercício sugerido. Leia os títulos das quatro partes Kafka e, para cada uma, escreva uma frase dizendo o que mudaria no Alfabetiza Cursor se você implementasse só aquela parte. Isso prepara respostas orais na banca.

Frente C. Cloud AWS Glue e buckets SOR, SOT e SPEC

A pasta três, Cloud, traz jobs etl bronze, etl silver e etl gold. Eles usam AWS Glue com Spark. Parâmetros típicos incluem nome do job, entidade e buckets.

SOR é a zona de dados brutos, equivalente à Bronze. SOT é a zona tratada, equivalente à Silver. SPEC é a zona de consumo analítico, equivalente à Gold. Essa nomenclatura aparece na aula e deve aparecer no seu README e no vídeo.

O job bronze da aula busca dados, por exemplo de uma API, adiciona metadados como timestamp de ingestão e escreve Parquet particionado no bucket SOR. O job silver lê SOR, tipa e limpa, e escreve no SOT. O job gold lê SOT, agrega e escreve no SPEC.

FinOps entra aqui. Glue sob demanda evita cluster ligado o tempo todo. Parquet e partições reduzem scan. Logs e parâmetros claros evitam reexecução às cegas. Desenvolver localmente com amostras reduz custo a quase zero.

No Alfabetiza Cursor, o arquivo glue jobs template documenta esses jobs. Mesmo que a demo principal rode local, você cumpre o requisito de desenho em nuvem explicando a arquitetura AWS e mostrando o

caminho de deploy.

Módulo 5. Qualidade, monitoramento e FinOps

Esses temas atravessam todas as aulas, embora o enunciado destaque qualidade como obrigatória e monitoramento como fortemente desejável.

Qualidade

Implemente e saiba explicar quatro checagens. Duplicidade por chave natural. Nulos em campos críticos. Integridade referencial entre município, UF, indicador e alunos. Consistência entre tabelas, por exemplo anos do indicador cobertos pela meta.

No projeto, o módulo `quality.validate` gera um relatório JSON. A pipeline orquestrada falha se a qualidade falhar. Isso é uma boa prática de governança: não publicar Gold suja.

Monitoramento

Observe falhas de ingestão, volume processado, latência total e alertas. No projeto, os arquivos de log e o monitor health cobrem o básico. Na AWS, o passo natural seria CloudWatch sobre jobs Glue.

FinOps

Conte no README quais decisões reduzem custo: formato Parquet, particionamento, compute sob demanda, amostras locais e qualidade cedo. Traga uma estimativa de ordem de grandeza para demo acadêmica.

Módulo 6. Como montar o projeto do zero, unindo as quatro aulas

Este módulo é o roteiro prático de conclusão.

Passo 1. Entender o domínio

Leia o PDF do Tech Challenge e o contexto de negócio do repositório. Decore: ponto de corte setecentos e quarenta e três; meta dois mil e trinta; entidades UF, município, metas e alunos.

Passo 2. Modelar como relacional

Desenhe no papel dimensões e fatos, inspirado na aula de MySQL. Confirme as chaves id UF, id município e ano. Implemente ou revise o SQL do projeto.

Passo 3. Definir origens e eventos NoSQL

Batch: Base dos Dados ou amostras CSV. Streaming: eventos JSON de atualização do indicador, no espírito DynamoDB Streams.

Passo 4. Implementar medalhão

Siga a ordem da aula de Big Data: origens, bronze, silver, gold. No Alfabetiza Cursor isso já está nos

scripts load. Rode a pipeline com streaming e confira as pastas data.

Passo 5. Acrescentar a narrativa de ETL cloud e Kafka

No README, desenhe batch mais Kafka mais Glue SOR SOT SPEC. Mostre o template Glue e o producer. Explique trade-offs: batch versus streaming; lake versus warehouse; custo versus performance.

Passo 6. Qualidade, FinOps e Git

Rode a validação. Escreva a seção FinOps. Garanta branches feat e merges ou pull requests na main. Há um arquivo de fluxo Git na pasta docs.

Passo 7. README, vídeo e entrega

Complete o README com todos os blocos do enunciado. Grave o vídeo com o roteiro de cinco minutos. Suba o repositório público e envie o que o AVA pedir.

Módulo 7. Comandos essenciais do Alfabetiza Cursor

Crie e ative o ambiente virtual Python. Instale as dependências do arquivo requirements. Rode o módulo pipelines.run_pipeline com a opção with-streaming. Rode o módulo pipelines.monitor_health. Rode o módulo quality.validate se quiser ver só a qualidade. Abra os CSV em reports gold preview para a apresentação.

Se HEALTH estiver OK e a qualidade estiver passed igual a true, a demonstração técnica local está pronta.

Módulo 8. Como falar na banca ou no vídeo sem travar

Estrutura sugerida de fala. Primeiro, o problema social e o indicador. Segundo, por que engenharia de dados: fontes heterogêneas. Terceiro, arquitetura híbrida e medalhão, citando a aula de Big Data. Quarto, AWS Glue e SOR SOT SPEC, citando a aula de ETL. Quinto, Kafka e eventos NoSQL para o frescor do dado. Sexto, MySQL para dimensões governadas. Sétimo, qualidade e FinOps. Oitavo, potencial de IA sobre a Gold. Nono, fechamento com valor para política pública até dois mil e trinta.

Frase útil. Nós não reinventamos a arquitetura: adaptamos o esqueleto das disciplinas da Fase 2 ao domínio do Indicador Criança Alfabetizada.

Módulo 9. Checklist final de conclusão

Negócio. Consigo explicar o ponto de corte e a meta dois mil e trinta. Relacional. Consigo explicar chaves e dimensões UF e município. NoSQL. Consigo explicar um evento JSON de atualização. Medalhão. Consigo contrastar Bronze, Silver e Gold com exemplos do projeto. ETL. Consigo explicar batch Pandas e o caminho Glue. Kafka. Consigo explicar producer, tópico e consumer. Qualidade. Tenho relatório passed. FinOps. Tenho parágrafo de custo no README. Git. Tenho branches e histórico de integração. Vídeo. Tenho roteiro ensaiado em até cinco minutos. Repositório. README completo e pipeline reproduzível.

Módulo 10. Links dos quatro materiais da turma

Arquitetura de Big Data.

https://github.com/AnaRaquelCafe/POSTECH_AI_SCIENTIST/tree/main/Fase%202/Arquitetura%20de%20Big%20Data

Banco de dados relacionais para cientistas de dados.

https://github.com/AnaRaquelCafe/POSTECH_AI_SCIENTIST/tree/main/Fase%202/Banco%20de%20dados%20relacionais%20para%20cientistas%20de%20dados

NoSQL para ciência de dados.

https://github.com/AnaRaquelCafe/POSTECH_AI_SCIENTIST/tree/main/Fase%202/NoSQL%20para%20ci%C3%Aancia%20de%20dados

ETL Pipelines.

https://github.com/AnaRaquelCafe/POSTECH_AI_SCIENTIST/tree/main/Fase%202/ETL%20Pipelines

Repositório do projeto desta entrega: pasta Alfabetiza Cursor, dentro de FIAP na Área de Trabalho do OneDrive. Há também o guia didático resumido na pasta docs, se quiser uma versão mais curta para ouvir antes da prova oral.

Encerramento

Se você estudar este guia na ordem dos módulos, terá a teoria das quatro disciplinas e o caminho concreto até fechar o Tech Challenge. O segredo não é memorizar cada linha de código das aulas. É entender o papel de cada peça e mostrar, no Alfabetiza Cursor, que essas peças se encaixam em uma pipeline híbrida medalhão a serviço da alfabetização.