

Roteiro por estágios — Tech Challenge Fase 2

Este documento ensina, em ordem, como o projeto Alfabetiza Cursor foi criado e o que ainda falta para concluir a entrega. Foi escrito para leitura em voz alta: sem cabeçalho, sem rodapé, sem número de página, com frases completas e estágios bem nomeados.

O enunciado oficial é o PDF IAST Tech Challenge Fase 2. A fonte de dados oficial é a Base dos Dados, conjunto Avaliação da Alfabetização, do Inep. O projeto fica na pasta FIAP, Alfabetiza Cursor.

Como usar. Os estágios um a seis mostram como replicar o que já foi feito. Os estágios sete a dez mostram o que falta para fechar a nota. Faça na ordem na primeira vez.

Visão geral dos dez estágios

Estágio um: entender o desafio e o domínio. Já feito nos documentos. Estágio dois: criar o repositório e a estrutura. Já feito. Estágio três: implementar o medalhão local, Bronze, Silver e Gold. Já feito com amostras. Estágio quatro: batch, streaming, qualidade e FinOps. Já feito. Estágio cinco: material didático e roteiro de vídeo. Já feito. Estágio seis: Git com branches e merges estilo pull request. Já feito no computador local. Estágio sete: trocar amostras pelos dados reais da Base dos Dados. Ainda a fazer. Estágio oito: evidência de cloud em AWS, GCP ou Azure. Ainda a fazer. Estágio nove: publicar no GitHub com pull requests reais. Ainda a fazer. Estágio dez: vídeo executivo e entrega no AVA. Ainda a fazer.

Parte A. Como o projeto foi criado, para replicar

Estágio 1. Entender o desafio e o domínio

Objetivo: saber o que entregar e por que os dados existem, antes de escrever código.

O que fazer. Leia o PDF do Tech Challenge Fase 2. Anote o ponto de corte setecentos e quarenta e três, a meta dois mil e trinta, a pipeline híbrida e o medalhão Bronze, Silver e Gold. Liste as entidades: unidade federativa, município, metas nacional, estadual e municipal, alunos e indicador. Abra a página da Base dos Dados do conjunto Avaliação da Alfabetização e entenda que a fonte oficial é o Inep.

Entregáveis deste estágio. Contexto mental claro, ou o arquivo de contexto de negócio preenchido. Checklist do enunciado separando o que é obrigatório do que é opcional.

No repositório já existem o contexto de negócio, o guia didático resumido em PDF e o guia extensivo das aulas POSTECH.

Estágio 2. Criar o repositório e a estrutura

Objetivo: ter uma pasta com Git e camadas alinhadas ao enunciado e às aulas da Pós Tech.

O que fazer. Crie a pasta Alfabetiza Cursor, por exemplo dentro de FIAP. Inicie o Git e use a branch main. Crie as pastas docs, diagrams, notebooks, pipelines batch, pipelines streaming, quality, sql, data com sample, raw, bronze, silver e gold, infra, references, reports, scripts e logs. Crie o README, o requirements e o gitignore. Abra essa pasta como workspace no Cursor.

Entregáveis. Repositório local com pastas e gitignore. Arquivo requirements com pandas, pyarrow e demais dependências básicas. No projeto atual também existe o mapa das aulas na pasta references.

Estágio 3. Medalhão local, Bronze, Silver e Gold

Objetivo: ter uma pipeline que roda no computador, gera as três camadas e os produtos analíticos pedidos no enunciado.

O que fazer. Primeiro, gere ou obtenha dados de entrada. No protótipo usamos data sample. Na Bronze, grave o dado bruto com metadados de data de ingestão e fonte, em Parquet particionado por data. Na Silver, limpe, tipe, deduplique e integre indicador com meta e município. Na Gold, materialize o indicador por município, a comparação entre meta e resultado por unidade federativa e pelo Brasil, e a evolução temporal. Orquestre tudo com um comando único.

Como replicar no terminal. Entre na pasta do projeto. Crie e ative o ambiente virtual Python. Instale as dependências do arquivo requirements. Rode o módulo pipelines.run_pipeline com a opção with-streaming. Rode o módulo pipelines.monitor_health.

Entregáveis. Scripts load bronze, load silver e load gold. Saídas nas pastas data bronze, silver e gold, e preview em reports gold preview. Relatório da pipeline na pasta logs. Também há o notebook que espelha os passos um a quatro do medalhão.

Estágio 4. Híbrido, qualidade e FinOps

Objetivo: cobrir batch mais streaming, qualidade de dados, custo e monitoramento básico.

O que fazer. No batch, ingira as tabelas históricas periodicamente. No streaming, use um producer de eventos de atualização do indicador, com file sink e, se quiser, Kafka. Na qualidade, verifique duplicidade, nulos, chaves e consistência entre tabelas. Documente FinOps: Parquet, particionamento, compute sob demanda e estimativa de custo. Faça um health check de latência, volume e falhas.

Entregáveis. Producer de eventos e consumer opcional. Script de qualidade com passed igual a true. Documento de FinOps e monitoramento, mais a seção correspondente no README. Template de jobs Glue e notas em infra. No estado atual, isso já foi validado localmente com amostras.

Estágio 5. Documentação didática e roteiro de vídeo

Objetivo: estudar e apresentar sem depender de ter visto todas as aulas.

O que fazer. Escreva um README completo com contexto, arquitetura, trade-offs, aplicação em IA e como reproduzir. Inclua diagrama ou fluxo de dados. Gere os PDFs resumido e extensivo. Escreva o roteiro do vídeo de até cinco minutos.

Entregáveis. README alinhado ao PDF do desafio. Arquivos de arquitetura e roteiro de vídeo. PDFs na pasta docs. Para regenerar os PDFs, rode os scripts generate guia didatico e generate guia extensivo.

Estágio 6. Git com evolução visível

Objetivo: cumprir a exigência de commits, branches e integração estilo pull request.

O que fazer. Trabalhe em branches com prefixo feat, por exemplo bronze, silver, gold e docs. Faça commits pequenos e descritivos. Integre na main com merge. No GitHub, o ideal é abrir pull requests de verdade. Isso fica no estágio nove.

No repositório local já existem branches feat e merges na main, além do arquivo de fluxo Git na pasta docs.

Parte B. O que falta para terminar a entrega

Estágio 7. Base dos Dados real. Prioridade um

Objetivo: substituir ou complementar as amostras sintéticas pelos dados oficiais do enunciado.

Passo um deste estágio. Crie um projeto no Google Cloud e copie o Project ID. Esse valor será o billing project id. Não é necessário cartão no modo sandbox. Há cerca de um terabyte gratuito de consulta por mês.

Passo dois. No ambiente virtual do projeto, instale o pacote basedosdados.

Passo três. Extraia primeiro as tabelas leves. O dataset é br inep avaliacao alfabetizacao. As tabelas iniciais são municipio e uf. Salve em data raw, por exemplo bd municipio ponto csv e bd uf ponto csv.

Passo quatro. Olhe as colunas e monte um mapa mental: ano, identificador de município, indicador de alfabetização e meta, se existir. Atualize o dicionário de dados.

Passo cinco. Só depois extraia alunos. Comece com limite para explorar, porque é microdado e pesa mais.

Passo seis. Adapte o load bronze, ou um script de fetch, para ler data raw em vez de depender só de data sample.

Passo sete. Ajuste a Silver aos nomes reais das colunas.

Passo oito. Rode de novo a pipeline e a qualidade.

Critério de pronto do estágio sete. Há CSV reais em data raw. Bronze, Silver e Gold rodam com esses dados. O README cita a Base dos Dados com link, dataset id e table id.

Exemplo de ideia do código de extração. Importe basedosdados. Defina o Project ID. Use read table para municipio e uf. Grave os CSV em data raw. Na primeira execução o navegador pede autorização da conta Google.

Estágio 8. Evidência de implementação em nuvem

Objetivo: atender o requisito de implementar em AWS, GCP ou Azure, não só no computador.

Opção um, alinhada à aula de ETL: Amazon S3 com buckets SOR, SOT e SPEC, mais um job Glue, mesmo que seja uma demonstração de uma entidade. Opção dois: Google Cloud, aproveitando que a Base dos Dados já está no BigQuery, com exportação para storage ou job agendado. Opção três, mínimo defensável: arquitetura documentada, template executável e evidência de uma execução cloud, como print

ou log.

Critério de pronto. README com diagrama cloud e trade-offs. Pelo menos uma evidência de execução ou deploy. Seção FinOps com estimativa realista. No projeto já existem o template Glue, o README de infra e o documento de arquitetura.

Estágio 9. GitHub público com pull requests reais

Objetivo: histórico Git visível na internet, com pull requests.

O que fazer. Crie um repositório público, por exemplo fiap alfabetiza fase dois. Adicione o remote origin e faça push da main. Abra uma branch feat, envie, crie o pull request, descreva a mudança e faça o merge. Cole o link do repositório no README e no AVA.

Critério de pronto. O repositório abre sem login. Há pelo menos um ou dois pull requests mergeados com descrição. Os commits mostram evolução: bronze, silver, gold e docs.

Estágio 10. Vídeo executivo e submissão na FIAP

Objetivo: fechar a apresentação executiva e a entrega formal, que concentram grande parte da nota.

O que fazer. Ensaie o roteiro de vídeo de até cinco minutos. Grave falando de problema de negócio, arquitetura da solução, valor para análises educacionais e potencial de inteligência artificial. Use linguagem para liderança, sem entrar em código. Suba o vídeo onde o AVA pedir. Envie link do GitHub, vídeo e o que mais a plataforma solicitar. Confira prazo e identificação do grupo.

Critério de pronto. Vídeo de até cinco minutos em linguagem executiva. Formulário do AVA salvo com sucesso. Link do GitHub testado em aba anônima.

Parte C. Ordem sugerida a partir de agora

Primeiro, faça o estágio sete: criar o Project ID no Google e extrair município e uf. Em seguida, ainda no sete, mapeie as colunas e adapte Bronze e Silver. Depois, publique no GitHub, estágio nove. Pode começar o push assim que tiver o primeiro CSV real. Em seguida, monte a evidência mínima de cloud, estágio oito. Por fim, grave o vídeo e entregue no AVA, estágio dez.

Opcional, só se sobrar tempo: enriquecimento com IBGE, Censo Escolar ou Cadastro Único. O PDF do desafio marca isso como opcional.

Parte D. Ligação com as quatro aulas da Pós Tech

Arquitetura de Big Data, notebooks um a quatro do medalhão, aparece nos scripts load e nos notebooks do projeto. ETL Pipelines, com Pandas, PySpark, Kafka e Glue, aparece na pasta streaming e no template Glue. Bancos relacionais aparece no SQL de dimensões MySQL. NoSQL e eventos aparece no producer de eventos em JSON tipado.

Há mais detalhes no arquivo mapa aulas, na pasta references, e no guia extensivo em PDF, na pasta docs.

Parte E. Como usar este roteiro no dia a dia

Para replicar o projeto do zero, siga os estágios um a seis. Para terminar a entrega da disciplina, siga os estágios sete a dez. Para estudar a teoria, ouça primeiro o guia didático resumido e depois o guia extensivo. Quando um estágio terminar, marque mentalmente ou anote no arquivo Markdown Roteiro Estágios do Projeto, na pasta docs, para não perder o fio.

Mensagem final. O medalhão local e a documentação já existem. O caminho crítico agora é dados reais da Base dos Dados, depois GitHub, cloud e vídeo. Faça um estágio por vez.